

在看 Classificational MedLDA 之前，先看一下 unsupervised LDA 模型。LDA(Latent Dirichlet allocation) 模型是一个生成模型，它刻画了一个语料(有很多的普通文档组成)每个文档各个位置的单词是怎么生成的，这有点类似于解数学题里的假设变量，求解变量的过程。

在 BleiNJ03 中是这样描绘该生成过程的：

1. Choose $N \sim \text{Poisson}(\xi)$.
2. Choose $\theta \sim \text{Dir}(\alpha)$.
3. For each of the N words w_n :
 - (a) Choose a topic $z_n \sim \text{Multinomial}(\theta)$.
 - (b) Choose a word w_n from $p(w_n | z_n, \beta)$, a multinomial probability conditioned on the topic z_n .

解释一下这个生成过程：

步骤 1~3 只是描述了一篇文档是怎么生成的，对于多篇文档，按照步骤 1~3 依次生成每篇文档。

过程中涉及到的变量和参数解释：

K ：主题个数

V ：词典中单词的个数

ξ ：泊松分布的参数，是个标量

N ：生成文档的长度，标量

α ：Dirichlet 分布的参数， K 维向量

θ ：生成文档的主题分布(多项分布)， K 维向量，在后面 θ_k 表示 θ 的第 k 个元素

w_n ：表示生成文档第 n 个位置的单词， V 维向量，如果 w_n 是单词 v ， $1 \leq v \leq V$ 并且为整数，则 w_n 的第 v 个位置元素为 1，其它元素均为 0。后面会涉及到一个相关的变量 w_n^v ，该变量是个标量，取值 0 或 1，若 w_n 是单词 v ，则 w_n^v 为 1，否则为 0，可以把它理解为 w_n 的第 v 个元素。

z_n ：表示生成文档第 n 个位置的单词所属于的主题， K 维向量，如果 z_n 是主题 k ， $1 \leq k \leq K$ 并且为整数，则 z_n 的第 k 个位置元素为 1，其它元素均为 0。后面会涉及到一个相关的变量 z_n^k ，该变量是个标量，取值 0 或 1，若 z_n 是主题 k ，则 z_n^k 为 1，否则为 0，可以把它理解为 z_n 的第 k 个元素。

β ： $K \times V$ 矩阵，行是主题，列是单词在词典中的索引。元素 $\beta_{i,j} = p(w^j = 1 \mid z^i = 1)$ ，即从主题 i 生成单词 j 的概率。 β 应该是按行正规化，

即每一行的元素加和为 1。后面用 β_i 表示 β 的第 i 行。(实际计算时按列正规化, 不过不是太重要)

步骤 1, 该文档按照参数 ξ 生成文档的长度 N 。在 BleiNJ03 中, 这样解释 N

that is to be estimated. Finally, the Poisson assumption is not critical to anything that follows and more realistic document length distributions can be used as needed. Furthermore, note that N is independent of all the other data generating variables (θ and z). It is thus an ancillary variable and we will generally ignore its randomness in the subsequent development.

在后面的模型中, 会忽略变量 N 。生成文档的长度取值实际文档的长度。

步骤 2, 从参数为 α 的 Dirichlet 分布生成文档的主题分布 θ ,

$$p(\theta \mid \alpha) = \frac{\Gamma(\sum_{i=1}^k \alpha_i)}{\prod_{i=1}^k \Gamma(\alpha_i)} \theta_1^{\alpha_1-1} \dots \theta_k^{\alpha_k-1}$$

步骤 3, 对于 N 个位置, 依次进行步骤(a), (b)。

步骤(a): 从参数为 θ 的多项分布生成主题 z_n ,

$$p(z_n^k = 1 \mid \theta) = \theta_k$$

步骤(b): 从参数为 β_k 的多项分布生成单词 w_n ,

$$p(w_n^v = 1 \mid \beta_k) = \beta_{kv} = p(w_n^v = 1 \mid \beta, z_n^k = 1)$$

对于一篇文档, 按照步骤 1~3 生成 θ , z , w 。 z 是 $K \times N$ 的矩阵, 即所生成文档的所有主题的表示, z_n 为其第 n 个元素。 w 是 $V \times N$ 的矩阵, 即所生文档所有单词的表示, w_n 为其第 n 个元素。

按照步骤 1~3, 把各个子步骤的概率相乘, 我们得到该篇文档的生成概率。

$$p(\theta, z, w \mid \alpha, \beta) = p(\theta \mid \alpha) \prod_{n=1}^N p(z_n \mid \theta) p(w_n \mid z_n, \beta) \quad (1)$$

在公式(1)中, 参数是 α 和 β , 即我们假设其是已知的, 最终要求解它们。而 θ , z 我们假设它们就是未知的, 最终也不需要求解出具体的数值, 我们称这种变量为隐含变量(latent variables), 隐含变量能够有效的刻画已知变量(这里是 w)之间的关系。

因为 θ , z 从始至终我们都把它们当作未知量, 所以要把它们积分出来, 这样就得到一篇实际文档(假设单词都已知, 就像本篇文档一样, 虽然还没写完, 为 w)的模型(LDA)概率:

$$\begin{aligned}
& p(w \mid \alpha, \beta) \\
&= \int \sum_z p(\theta, z, w \mid \alpha, \beta) d\theta = \int \sum_{z_1} \cdots \sum_{z_N} p(\theta, z, w \mid \alpha, \beta) d\theta \\
&= \int \sum_{z_1} \cdots \sum_{z_N} p(\theta \mid \alpha) \prod_{n=1}^N p(z_n \mid \theta) p(w_n \mid z_n, \beta) d\theta \\
&= \int p(\theta \mid \alpha) \left(\sum_{z_1} p(z_1 \mid \theta) p(w_1 \mid z_1, \beta) \right) \sum_{z_2} \cdots \sum_{z_N} \prod_{n=2}^N p(z_n \mid \theta) p(w_n \mid z_n, \beta) d\theta \\
&= \int p(\theta \mid \alpha) \left(\sum_{z_1} p(z_1 \mid \theta) p(w_1 \mid z_1, \beta) \right) \cdots \left(\sum_{z_N} p(z_N \mid \theta) p(w_N \mid z_N, \beta) \right) d\theta \\
&= \int p(\theta \mid \alpha) \left(\prod_{n=1}^N \sum_{z_n} p(z_n \mid \theta) p(w_n \mid z_n, \beta) \right) d\theta
\end{aligned}$$

一个语料(假设为 D , 共 M 篇文档), 每一篇文档都按照步骤 1~3 来生成, 我们得到该实际语料的模型(LDA)概率:

$$p(D \mid \alpha, \beta) = \prod_{d=1}^M \int p(\theta_d \mid \alpha) \left(\prod_{n=1}^{N_d} \sum_{z_{dn}} p(z_{dn} \mid \theta_d) p(w_{dn} \mid z_{dn}, \beta) \right) d\theta_d \quad (2)$$

公式(2)也是 LDA 模型我们最终要优化的目标函数。

先总结一下 LDA 模型,

两个参数: α, β

两个隐含变量: θ, z (定义1)

一个已知变量(或称观测变量): w

模型(由参数、变量、目标函数定义)我们知道是什么样子的, 下面的问题是怎么求解该模型, 即求解使公式(2)最大的参数值 $\hat{\alpha}, \hat{\beta}$ 。

对于这种带有隐含变量的模型, 一般的求解方法是 EM 算法。下面简单看一下 EM 算法。假设一个模型已知变量是 x , 参数是 Λ , 隐含变量是 h 。其似然函数是:

$$\begin{aligned}
L(\Lambda; x) &= \log p(x \mid \Lambda) \\
&= \log \sum_h p(x, h \mid \Lambda) \\
&= \log \sum_h q(h \mid x) \frac{p(x, h \mid \Lambda)}{q(h \mid x)} \\
&\geq \sum_h q(h \mid x) \log \frac{p(x, h \mid \Lambda)}{q(h \mid x)} \\
&\stackrel{\Delta}{=} L(q, \Lambda)
\end{aligned} \tag{3}$$

上面不等式的原理是 Jensen's inequality。Jensen's inequality 是说对于 concave function f (这里是 \log 函数), $f(E(x)) \geq E(f(x))$

我们将最大化 $I(\Lambda; x)$ 的问题转变为最大化其下界(lower bound) $L(q, \Lambda)$ 的问题。这里的下界并不是 $I(\Lambda; x)$ 的最小值, 而是另一个函数 $L(q, \Lambda)$, 该函数的曲线始终在原函数 $I(\Lambda; x)$ 之下。就像把一块布扣在一个倒置的碗上一样, 我们求不出布最高的位置的坐标(二维), 通过找出碗最高点的坐标来近似。

EM 算法每次迭代分为两个子步骤:

$$(E \text{ step}) \quad q^{(t+1)} = \arg \max L(q, \Lambda^{(t)})$$

$$(M \text{ step}) \quad \Lambda^{(t+1)} = \arg \max L(q^{(t+1)}, \Lambda)$$

E-step 我们假设维持 $\Lambda^{(t)}$ 不变, 改变 q 来使 L 变大。**M-step** 我们假设 $q^{(t+1)}$ 不变, 改变 Λ 来使 L 变大。可以证明, **E-step** 和 **M-step** 都可以使 L 变大或不变, 但不会变小。具体证明过程可以参考(Probabilistic graphical models, Jordan or Koller 的 EM 算法部分)。我们还可以证明, 如果 $p(h \mid x, \Lambda) = q(h \mid x)$ 的话可以使(3)不等式变为等式。

如果可以计算出 $p(h \mid x, \Lambda)$ 的话, 我们可以省略 **E-step** 而直接使用 **M-step**。

回到我们的 LDA 模型, 如果可以求解出 $p(\theta, z \mid w, \alpha, \beta)$ 的话, 就可以使优化问题变得相对简单一些(EM 算法里常用方法是在 **E-step** 求解隐含变量的后验概率, 很少有直接优化 **E-step** 本身的)。

但是:

$$p(\theta, z \mid w, \alpha, \beta) = \frac{p(\theta, z, w \mid \alpha, \beta)}{p(w \mid \alpha, \beta)}$$

其中

$$p(w \mid \alpha, \beta) = \int p(\theta \mid \alpha) \left(\prod_{n=1}^N \sum_{z_n} p(z_n \mid \theta) p(w_n \mid z_n, \beta) \right) d\theta$$

是计算不出来的。

所以使用另一个简单的分布 $q(\theta, z \mid \gamma, \phi)$ 来近似 $p(\theta, z \mid w, \alpha, \beta)$ 。通过公式(3)可以看出, 使用 $q(\theta, z \mid \gamma, \phi)$ 近似虽然不能求解出 $I(\Lambda; x)$ (这里是 $I(\alpha, \beta; w) = \log p(w \mid \alpha, \beta)$) 真实的最大值, 但能够保证求解出它的一个下界的最大值。

这种方法称为变分方法，这是因为 γ 和 ϕ 都是 $p(\theta, z \mid w, \alpha, \beta)$ 中没有的，这种方法的效果是在目标函数中增加了新的参数。 γ 和 ϕ 都是文档级的参数(相比之下， α 和 β 是语料级的参数)。 γ 是一个 K 维向量，是生成该文档 Dirichlet 分布的参数。 ϕ 是一个二维矩阵，行是单词的位置（或者说文档一个单词位置）的索引，列是主题的索引，元素 ϕ_{ni} 表示文档的第 n 个位置的单词属于主题 i 的概率。

$$q(\theta, z \mid \gamma, \phi) = q(\theta \mid \gamma) \prod_{n=1}^N q(z_n \mid \phi_n) = q(\theta \mid \gamma) q(z \mid \phi) \quad (4)$$

根据公式(3)中所示，对于一篇文档我们的优化目标由 $p(w \mid \alpha, \beta)$ 变成下面的函数：

$$\begin{aligned} \log p(w \mid \alpha, \beta) &= \log \int \sum_z p(\theta, z, w \mid \alpha, \beta) d\theta \\ &= \log \int \sum_z \frac{p(\theta, z, w \mid \alpha, \beta) q(\theta, z)}{q(\theta, z)} d\theta \\ &\geq \int \sum_z q(\theta, z) \log p(\theta, z, w \mid \alpha, \beta) d\theta - \int \sum_z q(\theta, z) \log q(\theta, z) d\theta \\ &= E_q[\log p(\theta, z, w \mid \alpha, \beta)] - E_q[\log q(\theta, z)] \\ &= L(w \mid \{\alpha, \beta\}, \{\gamma, \phi\}) = L(\gamma, \phi; \alpha, \beta) \end{aligned} \quad (5)$$

$L(\gamma, \phi; \alpha, \beta)$ 只是一种写法，该函数的参数有四个 α ， β (原有参数)和 γ ， ϕ (变分参数)。将公式(1)和(4)带入公式(5)中， $L(\gamma, \phi; \alpha, \beta)$ 变为下面的形式：

$$\begin{aligned} L(\gamma, \phi; \alpha, \beta) &= E_q[\log p(\theta \mid \alpha)] + E_q[\log p(z \mid \theta)] + E_q[\log p(w \mid z, \beta)] \\ &\quad - E_q[\log q(\theta)] - E_q[\log q(z)] \\ &= \log \Gamma(\sum_{j=1}^K \alpha_j) - \sum_{i=1}^K \log \Gamma(\alpha_i) + \sum_{i=1}^K (\alpha_i - 1) (\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j)) \\ &\quad + \sum_{n=1}^N \sum_{i=1}^K \phi_{ni} (\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j)) \\ &\quad + \sum_{n=1}^N \sum_{i=1}^K \sum_{j=1}^V \phi_{ni} w_n^j \log \beta_{ij} \\ &\quad - \log \Gamma(\sum_{j=1}^K \gamma_j) + \sum_{i=1}^K \log \Gamma(\gamma_i) - \sum_{i=1}^K (\gamma_i - 1) (\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j)) \\ &\quad - \sum_{n=1}^N \sum_{i=1}^K \phi_{ni} \log \phi_{ni} \end{aligned} \quad (6)$$

后五行分别是五个 E_q 分解开的结果，拿第一个来看看是怎么分解的。

$$\begin{aligned}
p(\theta \mid \alpha) &= \frac{\Gamma\left(\sum_{i=1}^K \alpha_i\right)}{\prod_{i=1}^K \Gamma(\alpha_i)} \theta_1^{\alpha_1-1} \dots \theta_K^{\alpha_K-1} \\
E_q[\log p(\theta \mid \alpha)] &= \int \sum_z q(\theta, z \mid \gamma, \phi) \log p(\theta \mid \alpha) d\theta \\
&= \int \sum_z q(\theta \mid \gamma) q(z \mid \phi) \log p(\theta \mid \alpha) d\theta \\
&= \int q(\theta \mid \gamma) \log p(\theta \mid \alpha) \sum_z q(z \mid \phi) d\theta \\
&= \int q(\theta \mid \gamma) \log p(\theta \mid \alpha) d\theta \\
&= \int q(\theta \mid \gamma) \log \frac{\Gamma\left(\sum_{i=1}^K \alpha_i\right)}{\prod_{i=1}^K \Gamma(\alpha_i)} \theta_1^{\alpha_1-1} \theta_K^{\alpha_K-1} d\theta \\
&= \int q(\theta \mid \gamma) \left(\log \Gamma\left(\sum_{i=1}^K \alpha_i\right) - \sum_{i=1}^K \log \Gamma(\alpha_i) + \sum_{i=1}^K (\alpha_i - 1) \log \theta_i \right) d\theta \\
&= \int q(\theta \mid \gamma) \left(\log \Gamma\left(\sum_{i=1}^K \alpha_i\right) - \sum_{i=1}^K \log \Gamma(\alpha_i) \right) d\theta + \int q(\theta \mid \gamma) \left(\sum_{i=1}^K (\alpha_i - 1) \log \theta_i \right) d\theta \\
&= \log \Gamma\left(\sum_{i=1}^K \alpha_i\right) - \sum_{i=1}^K \log \Gamma(\alpha_i) + \sum_{i=1}^K (\alpha_i - 1) \int q(\theta \mid \gamma) \log \theta_i d\theta \\
&= \log \Gamma\left(\sum_{i=1}^K \alpha_i\right) - \sum_{i=1}^K \log \Gamma(\alpha_i) + \sum_{i=1}^K (\alpha_i - 1) E_{q(\theta \mid \gamma)}[\log \theta_i] d\theta
\end{aligned} \tag{7}$$

上式中需要求解的一个量是 $E_{q(\theta \mid \gamma)}[\log \theta_i]$ ，在 BleiNJ03 A1 中，若

$$p(\theta \mid \alpha) = \frac{\Gamma\left(\sum_{i=1}^K \alpha_i\right)}{\prod_{i=1}^K \Gamma(\alpha_i)} \theta_1^{\alpha_1-1} \theta_K^{\alpha_K-1}$$

$$\text{则 } E_{p(\theta \mid \alpha)}[\log \theta_i \mid \alpha] = \Psi(\alpha_i) - \Psi\left(\sum_{j=1}^K \alpha_j\right)$$

这里比较有意思的一个问题是，从参数为 α 和参数为 γ 的 Dirichlet 分布我们都可以生成

θ 。那这里的 $E_{q(\theta \mid \gamma)}[\log \theta_i]$ 究竟应该是 $E_{q(\theta \mid \gamma)}[\log \theta_i \mid \alpha]$ 还是 $E_{q(\theta \mid \gamma)}[\log \theta_i \mid \gamma]$ 呢？我们可以

分析一下 $E_{q(\theta \mid \gamma)}[\log \theta_i]$ ，因为

$$E_{q(\theta \mid \gamma)}[\log \theta_i] = \int q(\theta \mid \gamma) \log \theta_i d\theta$$

因为我们要对 θ 求积分，那就是说 θ 是变化的，会取尽所有合法值。 $q(\theta \mid \gamma)$ 说明， θ 是

随着 γ 变化的，而不是随着 α 变化的。所以这里应该是 $E_{q(\theta \mid \gamma)}[\log \theta_i \mid \gamma]$ ，而不是

$E_{q(\theta \mid \gamma)}[\log \theta_i \mid \alpha]$ 。

所以可以继续公式(7)

$$= \log \Gamma\left(\sum_{i=1}^K \alpha_i\right) - \sum_{i=1}^K \log \Gamma(\alpha_i) + \sum_{i=1}^K (\alpha_i - 1) \left(\Psi(\gamma_i) - \Psi\left(\sum_{j=1}^K \gamma_j\right) \right)$$

其它四个 E_q 可以用类似的过程分解,最终得到公式(6)。

再总结一下 LDA 模型, 在 (定义 I) 中, LDA 模型的定义如下:

目标函数:

$$p(D | \alpha, \beta) = \prod_{d=1}^M p(w_d | \alpha, \beta) = \prod_{d=1}^M \int p(\theta_d | \alpha) \left(\prod_{n=1}^{N_d} \sum_{z_{dn}} p(z_{dn} | \theta_d) p(w_{dn} | z_{dn}, \beta) \right) d\theta_d$$

参数和变量:

两个参数: α , β

两个隐含变量: θ , z

一个已知变量(或称观测变量): w

然而我们无法优化上述模型, 所以采用了目标函数的一个下界来近似它, 并且采用了变分的方法。这样我们的模型就变成了如下形式:

目标函数:

$$\begin{aligned} l(D | \alpha, \beta; \gamma, \phi) &= \sum_{d=1}^D l(w_d | \alpha, \beta; \gamma_d, \phi_d) \\ &= \sum_{d=1}^D \log p(w_d | \alpha, \beta; \gamma_d, \phi_d) \\ &\geq \sum_{d=1}^D L(\alpha, \beta; \gamma_d, \phi_d) \end{aligned}$$

即我们的目标函数是 $\sum_{d=1}^D L(\alpha, \beta; \gamma_d, \phi_d)$

参数和变量:

四个参数: 一般参数 α , β 和变分参数 γ , ϕ

两个隐含变量: θ , z (定义 II)

一个已知变量(或称观测变量): w

虽然采用了变分方法, 但是参数的求解过程依然采用 EM 算法。

E-Step :

优化 $q(\theta, z | \gamma, \phi)$, 通过优化 γ , ϕ 实现

因为 γ , ϕ 是文档级的参数, 所以 M-Step 是逐篇文档进行。

对于一篇文档, 目标函数 $L(\gamma, \phi; \alpha, \beta)$ 如公式(6)所示,

$L(\gamma, \phi; \alpha, \beta)$ 中包含 ϕ_{ni} 的部分是:

$$L_{[\phi_{ni}]} = \phi_{ni} (\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j)) + \phi_{ni} \log \beta_{iv} - \phi_{ni} \log \phi_{ni} + \lambda_n (\sum_{j=1}^K \phi_{nj} - 1)$$

最后一项是拉格朗日因子, ϕ_{ni} 是个标量。

$L_{[\phi_{ni}]}$ 对 ϕ_{ni} 求导数, 结果如下:

$$\frac{\partial L}{\partial \phi_{ni}} = \Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j) + \log \beta_{iv} - \log \phi_{ni} - 1 + \lambda_n$$

令导数为 0 得:

$$\phi_{ni} \propto \beta_{iv} \exp(\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j))$$

$L(\gamma, \phi; \alpha, \beta)$ 中只包含 γ 的部分是

$$\begin{aligned} L_{[\gamma]} &= \sum_{i=1}^K (\alpha_i - 1) \left(\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j) \right) + \sum_{n=1}^N \phi_{ni} (\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j)) \\ &\quad - \log \Gamma(\sum_{j=1}^K \gamma_j) + \log \Gamma(\gamma_i) - \sum_{i=1}^K (\gamma_i - 1) (\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j)) \\ &= \sum_{i=1}^K \left(\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j) \right) \left(\alpha_i + \sum_{n=1}^N \phi_{ni} - \gamma_i \right) - \log \Gamma(\sum_{j=1}^K \gamma_j) + \log \Gamma(\gamma_i) \end{aligned}$$

$$\frac{\partial L}{\partial \gamma_i} = \Psi'(\gamma_i) \left(\alpha_i + \sum_{n=1}^N \phi_{ni} - \gamma_i \right) - \Psi'(\sum_{j=1}^K \gamma_j) \sum_{j=1}^K (\alpha_j + \sum_{n=1}^N \phi_{nj} - \gamma_j)$$

设置导数为 0, 得:

$$\gamma_i = \alpha_i + \sum_{n=1}^N \phi_{ni}$$

M-Step : 优化参数 α , β (它们是语料级参数)

$$L_{[\beta]} = \sum_{d=1}^M \sum_{n=1}^{N_d} \sum_{i=1}^K \sum_{j=1}^V \phi_{dni} w_{dn}^j \log \beta_{ij} + \sum_{i=1}^K \lambda_i (\sum_{j=1}^V \beta_{ij} - 1)$$

求解导数并设置为 0, 得:

$$\beta_{ij} \propto \sum_{d=1}^M \sum_{n=1}^{N_d} \phi_{dni} w_{dn}^j$$

$$L_{[\alpha]} = \sum_{d=1}^M \left(\log \Gamma(\sum_{j=1}^K \alpha_j) - \sum_{i=1}^K \log \Gamma(\alpha_i) + \sum_{i=1}^K \left((\alpha_i - 1) \left(\Psi(\gamma_{di}) - \Psi\left(\sum_{j=1}^K \gamma_{dj}\right) \right) \right) \right)$$

$$\frac{\partial L}{\partial \alpha_i} = M \left(\Psi\left(\sum_{j=1}^K \alpha_j\right) - \Psi(\alpha_i) \right) + \sum_{d=1}^M \left(\Psi(\gamma_{di}) - \Psi\left(\sum_{j=1}^K \gamma_{dj}\right) \right)$$

$$\frac{\partial L}{\partial \alpha_i \alpha_j} = \delta(i,j) M \Psi'(\alpha_i) - \Psi'(\sum_{j=1}^K \alpha_j)$$

α 不能准确地解出来，所以但其导数和曲率容易求解出来，一般采用牛顿方法进行优化。

(注： α ， β 和 γ ， ϕ 的计算细节仍需要整理)

ClassificationalMedLDA 是 MedLDA 的分类模型，它将 Maximum Likelihood 和 Max Margin 方法统一到一个目标函数中。

目标函数:

$$P3(\text{MedLDA}^c): \min_{q, q(\eta), \alpha, \beta, \xi} L^u(q; \alpha, \beta) + KL(q(\eta) \parallel p_0(\eta)) + \frac{C}{D} \sum_{d=1}^D \xi_d$$

$$\forall d, y \in C, s.t.: \begin{cases} E[\eta^T \Delta f_d(y)] \geq \Delta l_d(y) - \xi_d \\ \xi_d \geq 0 \end{cases} \quad (8)$$

在 unsupervised LDA 中，我们定义对于一篇文档，目标函数为 $L(\gamma, \phi; \alpha, \beta)$

这里我们改成另一种写法:

$$L(\gamma, \phi; \alpha, \beta) = L(q; \alpha, \beta)$$

值得注意的一点是在公式(8)中, $L^u(q; \alpha, \beta)$ 不同于 $L(q; \alpha, \beta)$ ，但是有下面的关系:

$$L^u(q; \alpha, \beta) = -L(q; \alpha, \beta) \quad (9)$$

其中 q 为 $q\{\theta_d, z_d\}$ 由公式(4)定义，它由参数 γ, ϕ 决定。

$$\Delta f_d(y) \stackrel{\Delta}{=} f(y_d, \bar{Z}_d) - f(y, \bar{Z}_d)$$

其中 $f(y, \bar{z})$ 是一个特征向量，元素从 $(y-1)K+1$ 到 yK 和 \bar{z} 相同，其它为 0。

$q(\eta)$ 是 η 服从的概率分布， η 是二维矩阵，行是类别，列是主题，元素 $\eta_{i,j}$ 衡量类别 i 在主题 j 上的权重。

α, β 和 unsupervised LDA 中的一样。

ξ 是 slack variable，为了解决数据不能由超平面绝对分开的问题。

在 MedLDA_JMLR 中，如果设置 ξ 为最优解，即

$\xi_d = \max_y (\Delta l_d(y) - E[\eta^T \Delta f_d(y)])$ 的话，公式(8)转换为下面的问题:

$$\min_{q, q(\eta), \alpha, \beta} L^u(q; \alpha, \beta) + KL(q(\eta) \parallel p_0(\eta)) + CR(q, q(\eta)) \quad (9)$$

其中:

$$R(q, q(\eta)) \stackrel{\Delta}{=} \frac{1}{D} \sum_{d=1}^D \max_{y \in C} (\Delta l_d(y) - E[\eta^T \Delta f_d(y)])$$

$R(q, q(\eta))$ 是下面预测函数:

$$\hat{y} = \arg \max_{y \in C} F(y; w) = \arg \max_{y \in C} E[\eta^T f(y, \bar{Z}) \mid \alpha, \beta, w]$$

预测误差的上界。 C 是正规化常数。

公式(8)中的参数是 α , β , $q(\eta)$, γ , ϕ , 隐藏变量是 θ , z 。可以采用梯度下降 (coordinate descent) 的方法优化其参数。因为含有隐含变量, 所以仍需要使用 EM 算法来进行优化。

E-step, 优化 $q\{\theta_d, z_d\}$ 即通过调整 γ , ϕ 来达到优化 $q\{\theta_d, z_d\}$ 的目的, 因为 γ , ϕ 决定了 $q\{\theta_d, z_d\}$ 。因为 $P3$ 中的不等式限制不包含 γ , 所以它的更新方法和 Unsupervised LDA 中的一样。

$P3$ 的 Lagrangian L 为:

$$L(q; q(\eta), \alpha, \beta, \mu, \xi) = L^u(q; \alpha, \beta) + \sum_{\eta} q(\eta) [\log q(\eta) - \log p_0(\eta)] + \frac{C}{D} \sum_{d=1}^D \xi_d - \sum_{y \in C} \sum_{d=1}^D \mu_d^y \{E[\eta^T \Delta f_d(y)] - \Delta l_d(y) + \xi_d\} - \sum_{d=1}^D \xi_d \delta_d \quad (10)$$

它的 Lagrange dual function 为

$$g(\mu, \delta) = \inf_{q; q(\eta), \alpha, \beta, \xi} L(q; q(\eta), \alpha, \beta, \xi, \mu, \delta)$$

inf 的意思是最大下界。主要这里最大下界与上面所说的下界(lower bound)的区别, 最大下界是一个函数值, 而下界是一个函数。对于函数 $L(q; q(\eta), \alpha, \beta, \xi, \mu_0, \delta_0)$, 假设 μ_0 , δ_0 为常数, $q, q(\eta), \alpha, \beta, \xi$ 为变量。 $L(q; q(\eta), \alpha, \beta, \xi, \mu_0, \delta_0)$ 的下界所能取得函数值并不一定比 $L(q; q(\eta), \alpha, \beta, \xi, \mu_0, \delta_0)$ 最大下界对应的函数值小。

假设:

$$L^{p3}(q; q(\eta), \alpha, \beta, \xi) = L^u(q; \alpha, \beta) + KL(q(\eta) \parallel p_0(\eta)) + \frac{C}{D} \sum_{d=1}^D \xi_d$$

$q^*; q^*(\eta), \alpha^*, \beta^*, \xi^*$ 是 $L^{p3}(q; q(\eta), \alpha, \beta, \xi)$ 的最优解。

则, 对于任意的 $\mu \geq 0, \delta$

$$g(\mu, \delta) \leq L^{p3}(q^*; q^*(\eta), \alpha^*, \beta^*, \xi^*)$$

这个式子左边是函数, 右边是函数值。

这个不等式的证明过程中会涉及到下界的问题，即：对于任意的 $\mu_0 \geq 0, \delta_0$

$$L(q; q(\eta), \alpha, \beta, \xi, \mu_0, \delta_0) \leq L^{p^3}(q; q(\eta), \alpha, \beta, \xi)$$

只保留 $L(q; q(\eta), \alpha, \beta, \mu, \xi)$ 中包含 ϕ_{ni} 的项,结果如下:

在无监督模型中,此项为:

$$L_{[\phi_{ni}]} = \phi_{ni}(\Psi(\gamma_i) - \Psi(\sum_{j=1}^K \gamma_j)) + \phi_{ni} \log \mathcal{B}_{iv} - \phi_{ni} \log \mathcal{B}_{ni} + \lambda_n (\sum_{j=1}^K \phi_{nj} - 1)$$

而现在:

$$\sum_{y \in C} \sum_{d=1}^D \mu_d^y E[\eta^T \Delta f_d(y)]$$

里也包含 ϕ_{ni}

在 Medlda_JMLR 中这样定义:

$$F(y, z, \eta; w) = \eta^T f(y, \bar{z}) = \eta_y^T \bar{z} \quad (11)$$

所以

$$F(y, w) = E_{q(\eta, z)}[F(y, z, \eta; w)] = \int \sum_z q(\eta, z) F(y, z, \eta; w) d\eta = \int \sum_z q(\eta, z) \eta_y^T \bar{z} d\eta \quad (12)$$

注意: 从 $F(y, z, \eta; w)$ 到 $F(y, w)$ 是取的期望而不是积分,

从公式(11)看出, η 与 z 是相互独立的。所以:

$$q(\eta, z) = q(\eta) * q(z)$$

继续公式(12),

$$= \int q(\eta) \eta_y^T d\eta \sum_z q(z) \bar{z} = E_{q(\eta)}[\eta_y] E_{q(z)}[\bar{Z}]$$

$$= E_{q(\eta)}[\eta_y] E_{q(z)}\left[\frac{1}{N} \sum_{n=1}^N Z_n\right]$$

$$= E_{q(\eta)}[\eta_y] \frac{1}{N} \sum_{n=1}^N E_{q(Z_n)}[Z_n]$$

$$= E_{q(\eta)}[\eta_y] \frac{1}{N} \sum_{n=1}^N \phi_n$$

$$E[\eta^T \Delta f_d(y)] = F(y_d, w_d) - F(y, w_d) = E[\eta_{y_d}] \frac{1}{N} \sum_{n=1}^N \phi_{dn} - E[\eta_y] \frac{1}{N} \sum_{n=1}^N \phi_{dn}$$

$$= \frac{1}{N} \{E[\eta_{y_d}] - E[\eta_y]\} \sum_{n=1}^N \phi_{dn}$$

所以

$$L_{[\phi_{dni}]}(q; q(\eta), \alpha, \beta, \mu, \xi) = -L_{[\phi_{dni}]} - \frac{1}{N} \{E[\eta_{y_d}] - E[\eta_y]\} \sum_{n=1}^N \phi_{dni}$$

对 ϕ_{dni} 求导，设置导数为 0，得：

$$\phi_{dn} \propto \exp \left(E[\log \theta_d | \gamma_d] + \log p(w_{dn} | \beta) + \frac{1}{N} \sum_{y \in C} \hat{\mu}_d^y E[\eta_{y_d} - \eta_y] \right)$$

M-step ,优化的参数是 $\alpha, \beta, q(\eta)$,因为 P3 中的不等式限制不包含 α, β ,所以它的更

新方法和 Unsupervised LDA 中的一样。下面考虑 $q(\eta)$ 怎么优化。

公式(10)对 $q(\eta)$ 求导数，得：

$$\begin{aligned} \frac{\partial L(q; q(\eta), \alpha, \beta, \mu, \xi)}{\partial q(\eta)} &= \log q(\eta) + q(\eta) \frac{1}{q(\eta)} - \log p_0(\eta) - \sum_{y \in C} \sum_{d=1}^D \mu_d^y \eta^T E[\Delta f_d(y)] \\ &= \log q(\eta) + 1 - \log p_0(\eta) - \eta^T \sum_{y \in C} \sum_{d=1}^D \mu_d^y E[\Delta f_d(y)] \end{aligned}$$

令其为 0，得：

$$q(\eta) = \frac{1}{Z} p_0(\eta) \exp \{ \eta^T \sum_{y \in C} \sum_{d=1}^D \mu_d^y E[\Delta f_d(y)] \}$$

所以： $\sum_{\eta} q(\eta) \{ \log q(\eta) - \log p_0(\eta) \}$

$$\begin{aligned} &= \sum_{\eta} q(\eta) \left\{ \log \left\{ \frac{1}{Z} p_0(\eta) \exp \{ \eta^T \sum_{y \in C} \sum_{d=1}^D \mu_d^y E[\Delta f_d(y)] \} \right\} - \log p_0(\eta) \right\} \\ &= \sum_{\eta} q(\eta) \left\{ \log p_0(\eta) + \eta^T \left\{ \sum_{y \in C} \sum_{d=1}^D \mu_d^y E[\Delta f_d(y)] \right\} - \log Z - \log p_0(\eta) \right\} \\ &= \sum_{\eta} q(\eta) \eta^T \left\{ \sum_{y \in C} \sum_{d=1}^D \mu_d^y E[\Delta f_d(y)] \right\} - \log Z \sum_{\eta} q(\eta) \\ &= \left\{ \sum_{y \in C} \sum_{d=1}^D \mu_d^y E[\Delta f_d(y)] \right\} \sum_{\eta} q(\eta) \eta^T - \log Z \\ &= \left\{ \sum_{y \in C} \sum_{d=1}^D \mu_d^y E[\Delta f_d(y)] \right\} E[\eta^T] - \log Z \end{aligned}$$

所以 P3 转换成下面的对偶问题：

$$D3: \max_{\mu} -\log Z + \sum_{d=1}^D \sum_{y \in C} \mu_d^y \Delta l_d(y)$$

$$\forall d, s.t.: \sum_{y \in C} \mu_d^y \in [0, \frac{C}{D}]$$

$$\text{假设 } \lambda = \sum_{d=1}^D \sum_{y \in C} \mu_d^y E[\Delta f_d(y)]$$

$$Z = \int_{\eta} p_0(\eta) \exp\{\eta^T \lambda\} d\eta$$

如果:

$$p_0(\eta) = N(0, I), \text{ 则 } p_0(\eta) = \frac{1}{\sqrt{2\pi}} \exp\{-\frac{\eta^2}{2}\}$$

$$\begin{aligned} Z &= \int_{\eta} \frac{1}{\sqrt{2\pi}} \exp\{-\frac{\eta^2}{2} + \eta^T \lambda\} d\eta \\ &= \int_{\eta} \frac{1}{\sqrt{2\pi}} \exp\{-\frac{(\eta - \lambda)^2 - \lambda^2}{2}\} d\eta \\ &= \exp\frac{\lambda^2}{2} \int_{\eta} \frac{1}{\sqrt{2\pi}} \exp\{-\frac{(\eta - \lambda)^2}{2}\} d\eta \\ &= \exp\frac{1}{2} \lambda^2 \end{aligned}$$

所以:

$$\begin{aligned} \log Z &= -\log\{\frac{1}{\sqrt{2\pi}}\} \\ &= -\frac{1}{2} \lambda^2 \end{aligned}$$

所以 D3 变为下面的问题:

$$\begin{aligned} \max_{\mu} -\frac{1}{2} \lambda^2 + \sum_{d=1}^D \sum_{y \in C} \mu_d^y \Delta l_d(y) \\ \forall d, s.t.: \sum_{y \in C} \mu_d^y \in [0, \frac{C}{D}] \end{aligned} \quad (13)$$

公式(13)的原始问题是:

$$\begin{aligned} \min_{\lambda, \xi} \frac{1}{2} \lambda^2 + \frac{C}{D} \sum_{d=1}^D \xi_d \\ \forall d, \forall y \in C, s.t.: \begin{cases} \lambda^T E[\Delta f_d(y)] \geq \Delta l_d(y) - \xi_d \\ \xi_d \geq 0 \end{cases} \end{aligned}$$